Análisis del sistema de colas en el restaurante Zarzamora mediante un modelo M/M/s en dos franjas horarias

Tomas Ortega
Juan Tellez
Paula García
Natalia Ramirez

2026

Resumen

El presente artículo analiza el comportamiento del sistema de colas en el restaurante Zarzamora, ubicado cerca de la universidad y caracterizado por ofrecer almuerzos tipo corrientazo con alta demanda, especialmente en horas pico. El restaurante cuenta con tres pisos, buen flujo de clientes y una atención generalmente eficiente. Durante la observación se identificó que el primer piso se llena rápidamente, por lo que muchos clientes se dirigen al segundo piso cuando la parte inferior está congestionada.

Para el análisis se realizaron dos sesiones de observación en franjas horarias distintas: la primera el 21 de abril de 2026, aproximadamente entre 1:22 p.m. y 2:20 p.m.; y la segunda el 22 de abril de 2026, entre 12:36 p.m. y 1:20 p.m.

A partir de los datos recolectados se estimaron las tasas de llegada y servicio, y se modeló el sistema mediante teoría de colas usando un modelo M/M/s implementado en Python. En la Sección 1 se obtuvo $\lambda = 1{,}276$ personas/minuto y $\mu = 0{,}621$ personas/minuto por servidor. En la Sección 2 se obtuvo $\lambda = 1{,}023$ personas/minuto y $\mu = 0{,}432$ personas/minuto por servidor.

Los resultados muestran que, aunque el restaurante tiene una alta capacidad de movimiento, el modelo con dos servidores presenta utilizaciones superiores al 100 %, lo que indica congestión temporal en momentos de alta demanda. Al evaluar escenarios con más servidores, se encontró que trabajar con tres servidores mejora considerablemente el desempeño: en la Sección 1 la satisfacción estimada aumenta a 99.08 % y la espera promedio baja a 0.48 minutos; en la Sección 2 la satisfacción alcanza 90.45 % y la espera promedio baja a 1.33 minutos.

Se concluye que Zarzamora cuenta con un buen flujo operativo y una atención adecuada para una zona universitaria de alta demanda. Sin embargo, para mejorar la experiencia del cliente durante las franjas de mayor congestión, se recomienda reforzar temporalmente la atención. Dado que durante la observación se identificaron dos meseros activos en el primer piso, sin contar a la persona encargada de la caja, el resultado del modelo sugiere aumentar a tres servidores o meseros por piso durante las horas pico. Esta recomendación se plantea replicando el análisis del primer piso en los tres niveles del restaurante, con el fin de reducir la congestión y mejorar los tiempos de espera.

Palabras clave: teoría de colas, M/M/s, restaurante, simulación, Python, tiempos de espera, Zarzamora.

1. Introducción

Los sistemas de colas aparecen en situaciones donde un conjunto de personas, clientes o usuarios deben esperar para recibir un servicio. Este fenómeno es común en bancos, supermercados, hospitales, estaciones de transporte, restaurantes y otros espacios donde la demanda puede superar temporalmente la capacidad de atención. En el caso de los restaurantes ubicados cerca de universidades, las colas pueden aumentar de manera considerable durante las horas de almuerzo, debido a la llegada simultánea de estudiantes, docentes y trabajadores.

El restaurante Zarzamora fue seleccionado para este estudio porque se encuentra cerca de la universidad y presenta un flujo constante de personas que entran y salen. Además, durante la observación se evidenció que el restaurante cuenta con tres pisos. El primer piso tiende a llenarse rápidamente, por lo que muchas personas se dirigen al segundo piso, especialmente cuando la parte inferior está congestionada. Esta característica hace que el restaurante sea un caso adecuado para estudiar el comportamiento de un sistema de colas en un ambiente real.

La teoría de colas permite analizar este tipo de situaciones mediante indicadores como la tasa de llegada, la tasa de servicio, el tiempo promedio de espera, la utilización del sistema y el nivel de satisfacción. En este proyecto se aplicó un modelo M/M/s, donde las llegadas y los tiempos de servicio se consideran aleatorios, y donde s representa el número de servidores o puntos de atención disponibles. En el contexto del restaurante, un servidor representa principalmente un mesero o punto de atención operativa por piso.

El objetivo principal de este trabajo es analizar el sistema de colas del restaurante Zarzamora a partir de dos sesiones de observación y comparar el comportamiento del sistema en dos franjas horarias distintas. Para ello se recolectaron datos reales de entradas y salidas de personas,

se estimaron los parámetros del modelo, se simuló el sistema en Python y se evaluaron diferentes cantidades de servidores. Finalmente, se propone una mejora operativa basada en los resultados obtenidos.

2. Revisión de literatura

La teoría de colas es una rama de la investigación de operaciones que estudia sistemas donde las entidades deben esperar para recibir un servicio. Sus primeras aplicaciones se relacionan con el análisis de congestión en sistemas telefónicos, especialmente a partir de los trabajos de Erlang. Posteriormente, Kendall propuso una notación para clasificar los sistemas de colas según el tipo de llegada, el tipo de servicio y el número de servidores.

Uno de los modelos más utilizados es el M/M/s. En esta notación, la primera M indica que las llegadas siguen un proceso Markoviano o Poisson, la segunda M indica que los tiempos de servicio siguen una distribución exponencial, y la letra s representa el número de servidores disponibles. Este modelo permite analizar sistemas con múltiples puntos de atención y resulta útil para estudiar restaurantes, bancos, centros de llamadas y servicios de atención al cliente.

En un sistema de colas, la tasa de llegada λ representa la cantidad promedio de clientes que llegan por unidad de tiempo, mientras que la tasa de servicio μ representa la cantidad promedio de clientes que puede atender cada servidor por unidad de tiempo. Cuando la tasa de llegada se acerca o supera la capacidad total de servicio, el sistema puede congestionarse y los tiempos de espera aumentan. Por esta razón, la utilización del sistema es un indicador importante para evaluar si la capacidad disponible es suficiente.

La simulación de eventos discretos permite representar sistemas reales en los que los eventos ocurren en momentos específicos, como la llegada de un cliente, el inicio de un servicio o la salida del sistema. Esta técnica es útil cuando el sistema tiene variabilidad e incertidumbre, ya que permite repetir el experimento varias veces y observar resultados promedio. En este proyecto se utilizó Python y la librería SimPy, la cual permite modelar procesos y recursos de capacidad limitada, como servidores o puntos de atención.

La simulación Monte Carlo también está relacionada con este tipo de análisis, ya que utiliza números aleatorios para representar posibles escenarios. En sistemas de colas, esta técnica ayuda a evaluar diferentes configuraciones antes de realizar cambios reales en el sistema. Por ejemplo, se puede simular qué pasaría si el restaurante aumenta de dos a tres servidores durante la hora pico, o si reorganiza la atención por piso.

En restaurantes y servicios de comida, el tiempo de espera tiene un impacto directo en la

percepción del servicio. Cuando los clientes deben esperar demasiado, la satisfacción disminuye y se pueden generar cuellos de botella en el proceso. Estudios aplicados a restaurantes han mostrado que el análisis de colas puede ayudar a reducir tiempos de servicio, mejorar la distribución del personal y aumentar la eficiencia operativa.

Para esta revisión de literatura se utilizaron herramientas de apoyo basadas en inteligencia artificial, como Elicit, Consensus, Research Rabbit y SciSpace. Estas herramientas permitieron identificar conceptos y fuentes relacionadas con teoría de colas, simulación de eventos discretos y aplicaciones en servicios. Sin embargo, la selección final de las referencias se realizó considerando su relación directa con el tema del proyecto.

3. Metodología

3.1. Tipo de estudio

El estudio es de tipo cuantitativo aplicado, basado en observación directa y simulación. Se recolectaron datos reales del comportamiento de entrada y salida de clientes en el restaurante Zarzamora durante dos franjas horarias. Posteriormente, los datos fueron utilizados para estimar los parámetros del modelo de colas y simular diferentes escenarios de atención.

3.2. Lugar de observación

El lugar seleccionado fue el restaurante Zarzamora, un establecimiento cercano a la universidad. El restaurante cuenta con tres pisos y presenta un alto flujo de personas durante las horas de almuerzo. Durante la primera toma de datos, al llegar al restaurante, se observó que la parte inferior estaba llena. Esto indica que el sistema ya se encontraba con una alta ocupación al inicio de la observación.

El primer piso funciona como una zona de alta rotación, ya que se llena rápidamente. Por esta razón, muchos clientes se dirigen al segundo piso, donde suelen ubicarse cuando el primer piso está saturado. Esta dinámica entre pisos fue considerada importante para interpretar los resultados, debido a que el flujo de personas no se concentra en un solo espacio, sino que se distribuye dentro del restaurante.

Durante la observación se identificaron dos meseros activos en el primer piso. El restaurante también cuenta con una persona encargada de la caja; sin embargo, esta no fue considerada como servidor dentro del modelo, debido a que su función principal corresponde al proceso de pago y no

directamente a la atención operativa por piso.

3.3. Sesiones de observación

Se realizaron dos sesiones de observación:

- **Sección 1:** realizada el 21 de abril de 2026, aproximadamente entre 1:22 p.m. y 2:20 p.m. Esta sesión corresponde a una franja con alto flujo de personas. Aunque la planeación inicial de observación estaba relacionada con la franja 1:12 p.m. a 2:00 p.m., los registros utilizados en el modelo corresponden a los eventos observados entre 1:22 p.m. y 2:20 p.m.
- **Sección 2:** realizada el 22 de abril de 2026, entre 12:36 p.m. y 1:20 p.m. Esta sesión también corresponde a una franja de almuerzo, pero presentó menor movimiento total en comparación con la primera.

3.4. Variables recolectadas

En cada sesión se registraron las siguientes variables:

- Número de iteración.
- Hora del evento.
- Piso donde ocurrió el evento.
- Número de personas que entran.
- Número de personas que salen.
- Total de movimientos.

El total de movimientos se calculó como la suma entre las personas que entran y las personas que salen en cada iteración. Es importante aclarar que esta variable no representa clientes únicos, sino movimientos observados dentro del sistema.

3.5. Modelo de colas utilizado

El sistema fue modelado como una cola M/M/s. En este modelo:

- La primera M representa llegadas aleatorias.
- La segunda M representa tiempos de servicio aleatorios.
- La letra s representa el número de servidores.

Para este proyecto, los servidores representan principalmente meseros o puntos de atención operativa del restaurante. La persona encargada de la caja no fue incluida como servidor dentro del modelo, ya que su función corresponde al proceso de pago y no directamente a la atención en mesa o gestión del flujo por piso. Durante la observación se identificaron dos meseros activos en el primer piso, por lo que el modelo base se evaluó con dos servidores. Posteriormente, se probaron escenarios con tres, cuatro y cinco servidores para analizar cómo cambiarían la espera promedio, la utilización y la satisfacción del cliente.

3.6. Estimación de parámetros

La tasa de llegada se calculó mediante la ecuación:

$$\lambda = \frac{\text{personas que entran}}{\text{duración observada}} \tag{1}$$

La tasa de servicio por servidor se estimó como:

$$\mu = \frac{\text{personas que salen}/\text{duración observada}}{\text{servidores base}} \tag{2}$$

Para estimar la tasa de llegada λ, se utilizaron únicamente las personas que ingresaron al restaurante durante la observación. Las personas que salieron se usaron para estimar la tasa de servicio μ, entendida como una aproximación de la capacidad de atención del sistema. El total de movimientos, calculado como entradas más salidas, se empleó solo como indicador descriptivo del flujo general del restaurante, no como tasa de llegada.

Para el modelo base se usaron dos servidores, correspondientes a los dos meseros observados en el primer piso. La satisfacción se definió como el porcentaje de clientes simulados que esperan cinco minutos o menos en la cola.

3.7. Herramientas utilizadas

El análisis fue realizado en Python. Se utilizaron las siguientes librerías:

- **SimPy:** para la simulación de eventos discretos.
- **NumPy:** para generación de valores aleatorios y cálculos numéricos.
- **Pandas:** para organizar los datos en tablas.
- **Matplotlib y Seaborn:** para construir visualizaciones.

4. Resultados

4.1. Resumen de los datos observados

La Tabla 1 muestra el resumen de las dos sesiones de observación. La Sección 1 tuvo una duración observada de 58 minutos, con 74 personas entrando y 72 personas saliendo. La Sección 2 tuvo una duración de 44 minutos, con 45 personas entrando y 38 personas saliendo.

Cuadro 1: Resumen de datos observados en Zarzamora

Sesión	Duración	Entran	Salen	Movimientos
Sección 1	58 min	74	72	146
Sección 2	44 min	45	38	83

Los datos muestran que la Sección 1 tuvo mayor movimiento total que la Sección 2. Esto indica que la primera franja observada presentó mayor flujo de personas y, por tanto, mayor presión sobre el sistema de atención.

4.2. Parámetros estimados

La Tabla 2 presenta los parámetros estimados para el modelo. En la Sección 1 se obtuvo una tasa de llegada de 1.276 personas/minuto y una tasa de servicio de 0.621 personas/minuto por servidor. En la Sección 2 se obtuvo una tasa de llegada de 1.023 personas/minuto y una tasa de servicio de 0.432 personas/minuto por servidor.

Cuadro 2: Parámetros estimados del modelo

Sesión	λ **pers/min**	μ **pers/min por servidor**
Sección 1	1.276	0.621
Sección 2	1.023	0.432

La Sección 1 presentó una tasa de llegada mayor, lo que significa que en esa franja ingresaron más personas por minuto. Sin embargo, la Sección 2 presentó una menor tasa de servicio estimada, lo que también puede generar congestión aunque tenga menos entradas.

4.3. Resultados del modelo M/M/s

La Tabla 3 presenta los resultados de la simulación para dos, tres, cuatro y cinco servidores en cada sección. En esta tabla, la espera promedio y el tiempo en el sistema están expresados en minutos.

Cuadro 3: Resultados del modelo M/M/s

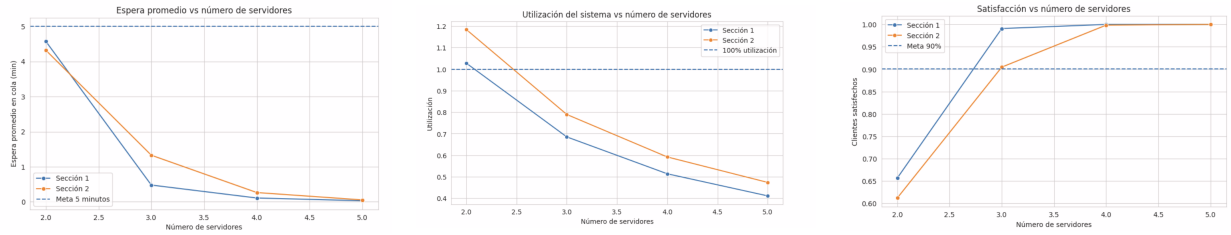
Sesión	**Serv.**	**Espera prom.**	**T. sistema**	**Satisfacción**	**Atendidos**	**Utilización**
Sección 1	2	4.57	6.10	65.66 %	64.00	102.78 %
Sección 1	3	0.48	1.97	99.08 %	72.17	68.52 %
Sección 1	4	0.11	1.67	100.00 %	70.73	51.39 %
Sección 1	5	0.03	1.62	100.00 %	68.80	41.11 %
Sección 2	2	4.32	6.29	61.20 %	33.50	118.42 %
Sección 2	3	1.33	3.45	90.45 %	40.27	78.95 %
Sección 2	4	0.27	2.53	99.84 %	40.20	59.21 %
Sección 2	5	0.06	2.22	100.00 %	44.33	47.37 %

Nota. La espera promedio y el tiempo en el sistema están expresados en minutos.

Con dos servidores, ambas secciones muestran niveles de utilización superiores al 100 %. En teoría de colas, una utilización mayor a 100 % indica que la demanda supera la capacidad de atención disponible. Por esta razón, el sistema tiende a congestionarse y los tiempos de espera aumentan.

En la Sección 1, con dos servidores, la espera promedio fue de 4.57 minutos y la satisfacción fue de 65.66 %. Al aumentar a tres servidores, la espera promedio disminuyó a 0.48 minutos

y la satisfacción aumentó a 99.08 %. En la Sección 2, con dos servidores, la espera promedio fue de 4.32 minutos y la satisfacción fue de 61.20 %. Al aumentar a tres servidores, la espera bajó a 1.33 minutos y la satisfacción subió a 90.45 %.



(a) Espera promedio

(b) Utilización

(c) Satisfacción

Figura 1: Indicadores del sistema según el número de servidores.

La Figura 1 muestra que al aumentar el número de servidores disminuye la espera promedio y la utilización del sistema, mientras que aumenta la satisfacción de los clientes. Con dos servidores, ambas secciones presentan alta carga operativa; en cambio, con tres servidores se alcanza la meta de satisfacción del 90 % y se reduce de forma importante el tiempo de espera.

4.4. Resumen de la Sección 1

Cuadro 4: Resumen del escenario: Sección 1

Indicador	**Valor**
Duración observada	58.00 min
Personas que entran	74
Personas que salen	72
Tasa de llegada λ	1.276 personas/min
Tasa de servicio μ	0.621 personas/min
Espera promedio con 2 servidores	4.57 min
Tiempo promedio en sistema con 2 servidores	6.10 min
Satisfacción con 2 servidores	65.66 %
Utilización con 2 servidores	102.78 %
Servidores recomendados	3
Satisfacción estimada con 3 servidores	99.08 %
Espera promedio con 3 servidores	0.48 min

4.5. Resumen de la Sección 2

Cuadro 5: Resumen del escenario: Sección 2

Indicador	Valor
Duración observada	44.00 min
Personas que entran	45
Personas que salen	38
Tasa de llegada λ	1.023 personas/min
Tasa de servicio μ	0.432 personas/min
Espera promedio con 2 servidores	4.32 min
Tiempo promedio en sistema con 2 servidores	6.29 min
Satisfacción con 2 servidores	61.20 %
Utilización con 2 servidores	118.42 %
Servidores recomendados	3
Satisfacción estimada con 3 servidores	90.45 %
Espera promedio con 3 servidores	1.33 min

4.6. Comparación entre franjas

La Tabla 6 compara los principales resultados de ambas franjas horarias. Esta comparación permite identificar cuál momento del día presentó mayor congestión, mayor demanda y mejor respuesta del sistema al aumentar el número de servidores.

Cuadro 6: Comparación general entre la Sección 1 y la Sección 2

Indicador	Sec. 1	Sec. 2
Duración obs. (min)	58.00	44.00
Entran	74	45
Salen	72	38
Movimientos	146	83
λ	1.276	1.023
μ	0.621	0.432
Espera 2 serv.	4.57	4.32
Satisf. 2 serv.	65.66 %	61.20 %
Utiliz. 2 serv.	102.78 %	118.42 %
Espera 3 serv.	0.48	1.33
Satisf. 3 serv.	99.08 %	90.45 %
Serv. recomendados	3	3

La comparación muestra que la Sección 1 tuvo mayor cantidad de personas entrando y saliendo, por lo que presentó mayor movimiento total. Esta franja corresponde a un momento de alta demanda, en el cual el restaurante ya tenía la parte inferior llena al inicio de la observación.

Por otro lado, aunque la Sección 2 tuvo menos entradas y salidas, presentó una utilización mayor con dos servidores. Esto se debe a que su tasa de servicio estimada fue menor, lo que significa que el sistema tenía menor capacidad relativa para atender a los clientes en esa franja.

En ambos casos, el modelo base con dos servidores no fue suficiente, ya que la utilización superó el 100 %. Al aumentar a tres servidores, las dos secciones alcanzaron la meta de satisfacción del 90 %. Por esta razón, la recomendación general es operar con tres servidores durante las franjas de mayor demanda.

5. Discusión

Los resultados obtenidos muestran que el restaurante Zarzamora presenta una alta demanda durante las franjas cercanas al almuerzo. Esta situación es coherente con el contexto del restaurante, ya que se encuentra cerca de una universidad y recibe un flujo constante de estudiantes. Además, la observación directa permitió identificar que el primer piso se llena rápidamente y que el segundo piso se convierte en una zona frecuente para los clientes cuando la parte inferior está congestionada.

El modelo base con dos servidores no resulta suficiente para ninguna de las dos secciones. En la Sección 1, la utilización fue de 102.78 %, mientras que en la Sección 2 fue de 118.42 %. Estos valores indican que la capacidad de atención disponible no alcanza a cubrir la demanda observada. Aunque la espera promedio con dos servidores fue cercana a cinco minutos, la satisfacción fue baja: 65.66 % en la primera sección y 61.20 % en la segunda. Esto significa que una parte importante de los clientes esperaría más de cinco minutos.

Al aumentar el sistema a tres servidores, los resultados mejoran considerablemente. En la Sección 1, la satisfacción sube a 99.08 % y la espera promedio baja a 0.48 minutos. En la Sección 2, la satisfacción llega a 90.45 % y la espera promedio baja a 1.33 minutos. Esto muestra que tres servidores son suficientes para alcanzar la meta de satisfacción planteada en ambas franjas.

Aunque usar cuatro o cinco servidores genera mejoras adicionales, estas no son tan necesarias desde el punto de vista operativo. En ambos casos, la satisfacción se acerca o llega al 100 %, pero el aumento de servidores implica mayor costo de personal. Por esta razón, tres servidores por piso durante las horas pico representan una solución equilibrada entre eficiencia y costo operativo, tomando como referencia la observación realizada en el primer piso.

La diferencia entre las dos secciones también es importante. La Sección 1 tuvo mayor movimiento total, con 74 entradas y 72 salidas. Esto confirma que fue una franja de mayor flujo. La Sección 2 tuvo menos entradas y salidas, pero una utilización más alta en el modelo base, lo que puede estar relacionado con menor capacidad efectiva de atención o mayor concentración de personas en ciertos momentos.

En términos prácticos, el restaurante podría mejorar su operación reforzando la atención durante las horas de mayor demanda. Esto no necesariamente significa contratar personal permanente adicional, sino activar un apoyo temporal en las horas pico. También se podría organizar mejor la atención por piso, de manera que los clientes no dependan únicamente de la capacidad del primer nivel cuando este se llena.

6. Propuesta de mejora

Con base en los resultados del modelo, se propone que el restaurante Zarzamora refuerce la atención durante las franjas de mayor demanda. La simulación mostró que pasar de dos a tres servidores mejora considerablemente el desempeño del sistema, ya que ambas secciones alcanzan o superan el 90 % de satisfacción.

Durante la observación se identificaron dos meseros activos en el primer piso. Además, el restaurante cuenta con una persona encargada de la caja, pero esta no fue considerada como servidor dentro del modelo, debido a que su función principal está relacionada con el pago y no con la atención directa del flujo de clientes por piso. Por esta razón, la recomendación se enfoca en los meseros o puntos de atención operativa.

A partir del resultado obtenido, se recomienda contar con tres servidores o meseros por piso durante las horas pico. Esta propuesta parte de la observación realizada en el primer piso y se replica para los tres niveles del restaurante, considerando que Zarzamora distribuye a sus clientes entre los diferentes pisos cuando el primer nivel se congestiona.

En la práctica, los tres servidores por piso podrían organizarse de la siguiente manera:

- Un servidor encargado de recibir o confirmar pedidos.
- Un servidor encargado de apoyar la atención de mesas y flujo de clientes.
- Un servidor encargado de entrega, apoyo operativo o coordinación con cocina y caja.

Esta estrategia no implica necesariamente aumentar permanentemente el personal, sino reforzar la operación en los momentos de mayor demanda, especialmente cuando ingresan grupos de

estudiantes. De esta forma, el restaurante podría reducir la congestión en el primer piso, distribuir mejor la atención entre los tres niveles y mejorar la experiencia del cliente sin cambiar la dinámica general del servicio.

7. Conclusiones

El análisis realizado permitió modelar el sistema de colas del restaurante Zarzamora usando un modelo M/M/s en Python. A partir de dos sesiones de observación, se estimaron las tasas de llegada y servicio, y se evaluaron diferentes cantidades de servidores.

La Sección 1 presentó mayor movimiento total, con 74 personas entrando y 72 saliendo durante 58 minutos. La Sección 2 presentó menor movimiento, con 45 entradas y 38 salidas durante 44 minutos. Sin embargo, ambas franjas mostraron congestión cuando el sistema operó con dos servidores.

Con dos servidores, la satisfacción fue de 65.66 % en la Sección 1 y 61.20 % en la Sección 2. Además, la utilización fue superior al 100 % en ambas franjas, lo que indica saturación del sistema. Esto demuestra que la capacidad base no es suficiente para atender adecuadamente la demanda durante las horas observadas.

La simulación mostró que trabajar con tres servidores mejora considerablemente el desempeño. En la Sección 1, la satisfacción aumentó a 99.08 % y la espera promedio bajó a 0.48 minutos. En la Sección 2, la satisfacción llegó a 90.45 % y la espera promedio bajó a 1.33 minutos.

Durante la observación se identificaron dos meseros activos en el primer piso. La persona encargada de la caja no fue incluida como servidor en el modelo, ya que su función principal corresponde al proceso de pago y no a la atención operativa por piso. Por esta razón, el análisis tomó como base los dos meseros observados en el primer piso y evaluó el efecto de aumentar la capacidad de atención.

Con base en los resultados, se recomienda que durante las horas pico el restaurante opere con tres servidores o meseros por piso. Esta recomendación se plantea replicando el análisis del primer piso en los tres niveles del restaurante, debido a que Zarzamora cuenta con tres pisos y el flujo de clientes se distribuye entre ellos cuando el primer piso se llena.

La mejora propuesta es realista porque no exige necesariamente una ampliación permanente del personal, sino una reorganización temporal de la atención en horas pico. Contar con tres servidores por piso permitiría atender mejor la alta entrada de grupos de estudiantes, reducir la congestión en el primer nivel y mejorar los tiempos de espera.

En conclusión, el modelo de colas permitió identificar que Zarzamora presenta alta demanda en las franjas cercanas al almuerzo y que un aumento moderado de la capacidad de atención puede reducir significativamente los tiempos de espera. Este tipo de análisis es útil para tomar decisiones operativas basadas en datos reales.

Referencias

[1] Erlang, A. K. (1909). *The theory of probabilities and telephone conversations*. Nyt Tidsskrift for Matematik B, 20, 33–39. Disponible en: https://www.scirp.org/reference/referencespapers?referenceid=2221031

[2] Kendall, D. G. (1953). Stochastic processes occurring in the theory of queues and their analysis by the method of the imbedded Markov chain. *The Annals of Mathematical Statistics, 24*(3), 338–354. Disponible en: https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-24/issue-3/Stochastic-Processes-Occurring-in-the-Theory-of-Queues-and-their/10.1214/aoms/1177728975.full

[3] Chaudhary, H., Sharma, G., Nishad, D. K., & Khalid, S. (2025). Advanced queueing and scheduling techniques in cloud computing using AI-based model order reduction. *Discover Computing, 28*, Article 75. https://doi.org/10.1007/s10791-025-09581-7

[4] Saini, B., Singh, D., & Sharma, K. C. (2024). Application of queueing theory to analyze the performance metrics of manufacturing systems. *Asian Research Journal of Mathematics, 20*(12), 84–95. https://doi.org/10.9734/arjom/2024/v20i12876

[5] SimPy. (2024). *SimPy documentation: Discrete event simulation for Python*. Disponible en: https://simpy.readthedocs.io/

[6] LearnPython.org. (s. f.). *Aprende Python*. Disponible en: https://www.learnpython.org/es/

[7] Lifeder. (s. f.). *Artículo científico: características, estructura y ejemplos*. Disponible en: https://www.lifeder.com/articulo-cientifico/

[8] SciELO Colombia. (2020). *Artículo científico publicado en revista indexada*. Disponible en: http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0120-87052020000200169

[9] Calcuvio. (s. f.). *Calculadora de velocidad*. Disponible en: https://www.calcuvio.com/velocidad

[10] Universidad del País Vasco. (s. f.). *Unidades de medida*. Disponible en: http://www.sc.ehu.es/sbweb/fisica_/unidades/unidades/unidades_1.xhtml

[11] Normas APA. (s. f.). *Formato APA*. Disponible en: https://normas-apa.org/formato/

[12] Python Software Foundation. (2020). *queue: Una clase de cola sincronizada*. Documentación de Python 3.8. Disponible en: https://docs.python.org/es/3.8/library/queue.html